

Aula 1

Princípios de Big Data

Felipe Alves



Objetivos

Desenvolver os princípios de Big Data, apresentando o histórico e a evolução da importância do tratamento de grande massa de dados, para aplicações de BIG DATA.

Ementa


- Princípios de Big Data.
- Hadoop e Armazenamento de Dados.
- Princípios de Desenvolvimento com PySpark.
- Análise de Dados em Python com Pandas.
- Big Data Analytics.

Volume de dados no mundo

- 1024 bytes = 1 kibibyte (KiB)
- 1024 kibibytes = 1 mebibyte (MiB)
- 1024 mebibytes = 1 gibibyte (GiB)
- 1024 gibibytes = 1 tebibyte (TiB)
- 1024 tebibytes = 1 pebibyte (PiB)
- 1024 pebibytes = 1 exbibyte (EiB)
- 1024 exbibytes = 1 zebibyte (ZiB)
- 1024 zebibytes = 1 yobibyte (YiB)



Motivação



- O aumento explosivo dos dados: de terabytes para petabytes
 - Coleção de dados e dados disponíveis
 - Ferramentas de coletas de dados automatizadas, SGBDs, Web, sociedade computadorizada
 - Maiores fontes de dados
 - Negócios: Web, e-commerce, transações, estoques, ...
 - Ciência: sensoriamento remoto, bioinformática, simulação científica, ...
 - Sociedade e pessoas comuns: notícias, dispositivos digitais, YouTube
- *We are drowning in data, but starving for knowledge!*
(*Estamos afogados em dados, mas famintos por conhecimento!*)
 - [Han]
- *Data mining* — automatiza a análise de conjuntos de dados em massa.

A lógica no uso dos dados


Os dados são usados e tratados na entrada, no monitoramento e nos resultados dos negócios

Assim, há uma grande chance de obtermos, em uma análise desses dados, resultados que permitam seu uso nas tomadas de decisões

Dado X Informação?



Data Science London
Free, open dissemination of data science. By data scientists, for data scientists.



Department of Computational and Data Sciences

TECNOLOGIA

Data mining ganha espaço na estratégia empresarial

Processo conquista organizações que buscam sair à frente da concorrência, aumentar os lucros e atender de forma mais eficiente às necessidades do cliente.

DÉBORAH OLIVEIRA, DA COMPUTERWORLD
19 de março de 2012 - 07h30

página 1 de 1

Importância dos dados


Vivemos em uma Sociedade Digital!

Conceito de Análise de Dados

- A ANÁLISE DE DADOS, também conhecida como descoberta de conhecimento em bases de dados; é o processo de busca e extração de conhecimento em volumes de dados.
- Alguns autores definem análise de dados como um processo não trivial, que busca **gerar conhecimento** potencialmente útil para **aumentar ganhos financeiros**, reduzir custos ou melhorar desempenhos nos negócios, através da procura e da identificação de padrões em dados armazenados em bases muitas vezes dispersas e inexploradas

Domínios

Knowledge Discovery in Databases – **KDD**



Panorama da área de Banco de dados

DBA

Administrador de dados

Arquiteto de dados

Engenheiro de dados

Analista de dados

Cientista de dados

Administrador de banco de dados - DBA

É a pessoa encarregada de instalar, configurar e gerenciar um SGBD. São suas funções:

- decidir como os dados serão representados no BD (projeto físico e lógico);
 - definir os controles de segurança e integridade;
 - definir estratégias de reserva e recuperação;
 - monitorar o desempenho das aplicações
-
- O Administrador de Dados é o DBA sênior que tem conhecimento de todas os bancos de dados da empresa

Arquiteto de Dados

- Trabalhar com os responsáveis pelos produtos para entender os requisitos, fornecer orientação sobre opções adequadas e ajudá-los a impulsionar as soluções de engenharia de dados em seus produtos;
- Criar cargas ETL com base em requisitos definidos em conjunto ao longo do pipeline de dados, incluindo ingestão, validação, transformação e armazenamento dos dados de vários sistemas de origem no data lake de acordo com a finalidade do uso.
- Trabalhar em estreita colaboração com os desenvolvedores de back end, grupo de arquitetura e cientista de dados e TI;
- Definir e criar pipelines de dados para produtos de analytics de dados;
- Auxiliar na correção de bug e análise de performance;
- Fornecer expertise em SQL, Data Warehouses e data Lakes à equipe de desenvolvimento;
- Seguir uma metodologia de desenvolvimento ágil.
- Sólidas habilidades analíticas, comunicação, documentação e atitude prática;
- Experiência na linguagem de programação R / Python;
- Experiência com computação distribuída e Cloud Computing (Hadoop, Dask, Hive, Spark, etc.
- Experiência em linguagens de programação: Shell Script, R, Terraform;
- Tecnologias em nuvem (Google, Azure, AWS).

Engenheiro de Dados

- Análise e solução de problemas, além de transitar muito bem entre tecnologia e negócios;
- Desenvolver novos estudos baseados em diferentes tipos de dados, extrair indicadores e insights;
- Experiência em ETL;
- Forte atuação em criação de relatórios e dashboards utilizando principais ferramentas;
- Conhecimento básico em Modelagem de Dados e Integração de Dados;
- Conhecimento em linguagens de programação de scripts;
- Conhecimento avançado em linguagem SQL;
- Conhecimento intermediário em levantamento de requisitos analíticos;
- Conhecimento básico em Big Data (Hive, Hadoop);
- Conhecimento avançado em criação de relatórios e dashboards.

Analista de Dados

- Dominar as regras do negócio, transformando dados brutos em inteligência nas tomadas de decisões;
- Trabalhar com outros profissionais da área de dados da empresa;
- Projetar e gerenciar bancos de dados para suportar as análises;
- Criar rotinas para extrair, transformar e carregar dados (ETL) de fontes diversas;
- Acompanhar resultados através da elaboração de dashboards para orientar as equipes a fim de resolver problemas, melhorias e tendências nos seus serviços baseados em dados.
- Elaborar relatórios gerenciais;
- Experiência em BI;
- Conhecimentos em SQL;
- Identificar oportunidades de negócios;
- Raciocínio analítico e afinidade com números.

Analista de Dados


Os dashboards e relatórios devem ser inteligentes e de fácil entendimento;

Faça-se importante na empresa no processo de tomada de decisões

Cientista de Dados

- Conduzir discussões com as partes interessadas da empresa para compreender as principais áreas de preocupação para a empresa e traduzi-las em problemas de ciência de dados;
- Participar do processo de construção de solução dentro de um ambiente multi-organizacional e facilitar as entradas de várias partes interessadas;
- Trabalhar com engenheiros de dados para reunir os dados necessários para engenharia de recursos e construção de modelos;
- Implementar soluções otimizando vários algoritmos de ML e estatísticos;
- Trabalhar com engenheiros de aprendizado de máquina para implantar modelos com práticas e processos recomendados de ML;
- Desenvolver materiais de comunicação e apresentação para as partes interessadas sênior e executiva para entender o progresso, resultados e desafios com vários modelos de ML;
- Analisar os resultados e apresentar às partes interessadas;
- Construir modelos estatísticos e de aprendizado de máquina para classificação, regressão, previsão, detecção de anomalias, clustering etc.;
- Habilidades na tradução de estatísticas em percepções. Conhecimento sólido em inferência estatística, teste de hipótese e teste A / B;
- Ferramentas de relatório

Processo para a geração de conhecimento (*KDD*)



Possíveis questões no processo

- Onde estão os dados?
- Precisam ser coletados?
- São estruturados?
- Como carregá-los para memória?
- Como identificar as variáveis relevantes?
- Como avaliar e melhorar a qualidade dos dados?
- Como saber se tem dados suficientes?
- Como transformar os dados para poder analisá-los?
- Como apresentar os resultados visualmente?

Volume de dados no mundo



BIG DATA NA AVIAÇÃO

DADOS GERADOS POR UM AVIÃO POR HORA DE VOO

 **+50.000**
SENSORES A BORDO

Sensores monitoram motores, sistemas e desempenho

 **+50 TB** DE DADOS
POR HORA

Airbus A350 e Boeing 787 podem gerar cerca de 50 Terabytes de dados cada hora voando

 **+20 MILHÕES**
DE MENSAGENS DE TELEMETRIA

Dados sobre altitude, velocidade, temperatura, etc.

 **ANÁLISE E
ARMAZENAMENTO**

Data Centers & Computação na Nuvem

 **TRANSMISSÃO EM TEMPO REAL**

Satélites & Comunicação
VIA LINKA

 **PROCESSAMENTO E MANUTENÇÃO PREDITIVA**

Utilização dos dados para manutenção e segurança

Tipos de dados

Dados estruturados

Ex.: Banco de dados

Estrutura rígida
Projetada previamente
Representação homogêna

Cada campo de dados tem um formato bem definido.

Formato é um padrão aceito pelo campo.

Dados de um mesmo registro possuem relação entre eles.

Registros possuem valores diferentes, mas mesmos atributos.

Atributos ou campos são definidos por um esquema.

Dados semi estruturados

Ex.: XML, JSON, RDF, OWL.

Estrutura flexível
Representação heterogêna

Cada campo de dados tem uma estrutura, mas não existe uma imposição de formato

O esquema é criado com a definição de elementos internos dos arquivos (nós), legíveis para seres humanos

Dados não estruturados

Ex.: Textos, arquivos, documentos, imagens, vídeos, áudios, redes sociais etc.

Sem estrutura
(ou com estrutura mínima de arquivo)

Mais de 80% dos dados gerados no mundo é deste tipo

Infraestrutura disponível



Processamento e armazenamento

Big data em destaque



A NOVIDADE


A grande novidade das soluções de Big Data é lidar também com os chamados dados não-estruturados, que até então só podiam ser compreendidos por pessoas. São tweets, posts no Facebook, vídeos, geolocalização e comportamentos de clientes que dependem de contexto para ter sentido.

Esses dados não-estruturados representam 85% das informações com as quais as empresas lidam hoje



O mercado de Big Data crescerá quase 40% ao ano até 2015

A quantidade global de dados digitais deve crescer de 1,8 zettabyte, hoje, para 7,9 zettabytes em 2015. Daqui a três anos, toda a informação do mundo poderá ser armazenada em:



COMPARE

1 Zettabyte é igual

1.000.000.000.000.000.000 bytes

1 Gigabyte é igual

1.000.000.000 bytes

Alguns exemplos de como a solução tem sido usada

A companhia Skybox tira fotos de satélite e vende a seus clientes informações em tempo real sobre a disponibilidade de vagas de estacionamento livres numa cidade em determinada hora ou quantos navios estão ancorados no mundo neste momento

O projeto Global Pulse, das Nações Unidas, vai utilizar um programa que decifra a linguagem humana na análise de mensagens de texto e posts em redes sociais para prever o aumento do desemprego, o esfriamento econômico e epidemias de doenças


A varejista americana Dollar General monitora as combinações de produtos que seus clientes põem nos carrinhos. GANHOU eficácia e ainda descobriu curiosidades: quem bebe Gatorade tem mais chances de comprar também laxante

A Sprint Nextel saltou da última posição no ranking de satisfação dos usuários de celular nos EUA ao integrar os dados de todos os seus canais de relacionamento. De quebra, cortou pela metade os gastos com call center

No terremoto do Haiti, pesquisadores americanos perceberam antes de todo mundo a diáspora de Porto Príncipe por meio dos dados de geolocalização de 2 milhões de chips SIM de celulares, facilitando a atuação da ajuda humanitária

Um hospital no Canadá usou tecnologia da IBM e da Universidade de Ontário para monitorar em tempo real dezenas de indicadores de saúde de bebês prematuros. O cruzamento permitiu aos médicos antecipar ameaças às vidas das crianças

Em busca dos melhores lugares para instalar turbinas eólicas, a dinamarquesa Vestas Wind analisou petabytes de dados climáticos, de nível das marés, mapas de desmatamento etc. O que costumava levar semanas durou algumas horas



Exemplos de aplicações com grande volumes de dados

Fonte: <http://oglobo.globo.com/infograficos/bigdata/>

Conceito de Big Data

- Aplica-se o termo a conjuntos de dados cujo volume e o tipo não podem ser trabalhados apenas nos bancos de dados tradicionais (relacionais);
- Tais conjuntos de dados tem como características, além do grande volume, a necessidade de um processamento com alta velocidade em tipos variados de dados (estruturados, semiestruturados e não estruturados);
- Ao analisar os dados, as empresas podem tomar decisões mais acertadas e com celeridade;
- As empresas podem utilizar técnicas avançadas de análise, como análise de texto, machine learning, análise preditiva, mineração de dados, estatística e processamento de linguagem natural para obter novos insights a partir de fontes de dados previamente não exploradas de forma independente ou junto a dados corporativos existentes.

Os 5Vs do Big data

Volume – grande volume de dados obtido de diversas fontes, tanto estruturados, como semiestruturados e não estruturados;

Velocidade – apesar do grande volume de dados, o processamento dos dados tem que ser rápido para permitir a viabilidade das análises;

Veracidade – faz referência a confiabilidade e qualidade dos dados;

Variedade – os SGBDs devem trabalhar com variados formatos de dados;

Valor – é a transformação de dados em informação relevante



Exemplos de aplicações com Big Data

- A inteligência artificial (IA), os dispositivos móveis, as redes sociais e a Internet das Coisas (IoT) estão aumentando a complexidade dos dados por meio de novas formas e fontes de dados;
- Por exemplo, o Big Data é obtido por meio de sensores, dispositivos, vídeo/áudio, redes, arquivos de log, aplicativos transacionais, web e mídias sociais;
- Grande parte dele é gerada em tempo real e em uma escala muito grande.

Big data e aplicações

Comportamentos e tendências – possibilita compreender o comportamento dos clientes e tendências de consumo. Um exemplo: após a aposentadoria, os profissionais que moram em cidades preferem continuar nas cidades ou mudar para o litoral ou o interior?

Planejamento de ações de marketing – a análise dos dados permite criar e monitorar com agilidade campanhas de marketing com o monitoramento dos resultados;

Melhoria de serviços e de produtos – os dados obtidos pelos comentários, elogios, reclamações e feedbacks dos usuários permitem a obtenção de *insights* que podem ser usados na melhoria desses produtos

Big data e aplicações

Mercado de investimentos – corretores de valores necessitam de analisar grandes volumes de dados de taxas, ações e variação de câmbio rapidamente para tomadas de decisões

Setor de saúde – vivenciamos atualmente o acompanhamento dos dados de uma pandemia e, a partir de análises dos dados, decisões foram tomadas

IoT - Internet das coisas (*Internet of things*) – com o aumento da velocidade de conexão, espera-se que a comunicação de máquinas gere um volume enorme de dados. Um exemplo são os dados gerados por sensores de temperatura



VOCÊ ESTÁ AQUI: PÁGINA INICIAL > NOTÍCIAS > MINISTÉRIO ENTREGA AOS ESTADOS PRIMEIRAS FERRAMENTAS DE BIG DATA E INTELIGÊNCIA ARTIFICIAL PARA COMBATER A CRIMINALIDADE

SEUS DIREITOS

Arquivo Nacional
Classificação
Indicativa
Consumidor

DESTAQUE

Ministério entrega aos estados primeiras ferramentas de Big Data e Inteligência Artificial para combater a criminalidade

Ministério da Justiça e Segurança Pública

O que você procura?

Ministério da Justiça e Segurança Pública lança aplicativo Sinesp Agente de Campo

Ferramenta permite acesso imediato a mandados de prisão e a dados de veículos roubados

<https://www.justica.gov.br/news/collective-ntf-content-1566331890.72>

<https://www.gov.br/mj/pt-br/assuntos/noticias/ministerio-da-justica-e-seguranca-publica-lanca-aplicativo-sinesp-agente-de-campo>

Perguntas comuns para um Analista de Dados

O que posso fazer pela minha empresa com seus dados?

Quais dados?

E a qualidade desses dados?

Quais análises?

Quais as ferramentas corretas para trabalhar com eles?

Como apresentar os resultados?

Iris Data Set

O **Iris Data Set** é um dos conjuntos de dados mais famosos da área de ciência de dados e aprendizado de máquina. Ele foi criado pelo estatístico e biólogo Ronald Fisher em 1936 e contém medições de flores da espécie *Iris*.

O que é o Iris Data Set

É um conjunto de dados que contém **150 registros de flores** divididos em **3 espécies diferentes de Iris**:

- Iris setosa
- Iris versicolor
- Iris virginica



Iris Versicolor



Iris Setosa



Iris Virginica

Cada flor possui **4 características medidas**:

- Comprimento da sépala
- Largura da sépala
- Comprimento da pétala
- Largura da pétala

E também possui a **classe**, que indica a espécie da flor.

Como o Iris Data Set é usado?

O Iris Data Set é usado principalmente para **ensinar e testar algoritmos de aprendizado de máquina**, especialmente para **classificação**.

Ele permite que um algoritmo aprenda a responder perguntas como:

"Com base nas medidas da flor, qual é a espécie?"

A visão do negócio a partir dos dados


comp_sepala,larg_sepala,comp_petala,larg_petala,classe

5.1,3.5,1.4,0.2,Iris-setosa
4.9,3.0,1.4,0.2,Iris-setosa
4.7,3.2,1.3,0.2,Iris-setosa
4.6,3.1,1.5,0.2,Iris-setosa
5.0,3.6,1.4,0.2,Iris-setosa
4.6,3.2,1.4,0.2,Iris-setosa
5.3,3.7,1.5,0.2,Iris-setosa
5.0,3.3,1.4,0.2,Iris-setosa
7.0,3.2,4.7,1.4,Iris-versicolor
6.4,3.2,4.5,1.5,Iris-versicolor
6.9,3.1,4.9,1.5,Iris-versicolor
5.6,3.0,4.5,1.5,Iris-versicolor
5.8,2.7,4.1,1.0,Iris-versicolor
6.2,2.2,4.5,1.5,Iris-versicolor
5.8,2.7,3.9,1.2,Iris-versicolor
6.0,2.7,5.1,1.6,Iris-versicolor
5.7,2.8,4.1,1.3,Iris-versicolor
6.3,3.3,6.0,2.5,Iris-virginica
5.8,2.7,5.1,1.9,Iris-virginica
7.1,3.0,5.9,2.1,Iris-virginica
6.3,2.9,5.6,1.8,Iris-virginica
6.5,3.0,5.8,2.2,Iris-virginica
7.6,3.0,6.6,2.1,Iris-virginica
4.9,2.5,4.5,1.7,Iris-virginica
7.3,2.9,6.3,1.8,Iris-virginica
6.7,2.5,5.8,1.8,Iris-virginica
7.2,3.6,6.1,2.5,Iris-virginica
6.5,3.2,5.1,2.0,Iris-virginica
6.4,2.7,5.3,1.9,Iris-virginica
6.8,3.0,5.5,2.1,Iris-virginica
5.7,2.5,5.0,2.0,Iris-virginica
5.8,2.8,5.1,2.4,Iris-virginica
6.4,3.2,5.3,2.3,Iris-virginica
6.5,3.0,5.5,1.8,Iris-virginica

Iris Data Set

◎ Muitas das técnicas exploratórias dos dados são ilustradas com o conjunto de dados Iris.

- Pode ser obtida no UCI Machine Learning Repository
<http://www.ics.uci.edu/~mlearn/MLRepository.html>
- Três tipos de flores (classes):
 - Setosa, Virgínica, Versicolor
- Quatro atributos
 - Largura e comprimento da sépala
 - Largura e comprimento da pétala



Observações da base Iris

- O conjunto de dados das flores contém 150 amostras;
- A largura da pétala é dividida nas categorias:
 - Pequena – $[0, 0.75]$;
 - Média – $[0.75, 1.75]$;
 - Grande – $[1.75, \infty]$.
- O comprimento da pétala é dividido nas categorias:
 - Pequena – $[0, 2.5]$;
 - Média – $[2.5, 5]$;
 - Grande – $[5, \infty]$.

Regras derivadas da base Iris

- Largura e comprimento pequenos de pétala significam Setosa;
- Largura e comprimento médios de pétala significam Versicolor;
- Largura e comprimento grandes de pétala significam Virgínica;
- Embora estas regras não classifiquem todas as flores, elas fazem um bom (mas não perfeito) trabalho de classificação na maioria das flores.

10 Bibliografia básica

FACELI, Katti. **Inteligência Artificial - Uma abordagem de aprendizado de máquina [BV:MB]**. 2ª Ed. Rio de Janeiro: LTC, 2021.

Disponível em: <https://integrada.minhabiblioteca.com.br/books/9788521637509/>

GOLDSCHMIDT, Ronaldo. **Data Mining - Conceitos, técnicas, algoritmos, orientações e aplicações [BV:MB]**. Rio de Janeiro: Elsevier, 2015.

Disponível em: <https://integrada.minhabiblioteca.com.br/books/9788595156395/>

PEREIRA, Mariana Araújo. **Framework de Big Data [BV:MB]**. Porto Alegre: SAGAH, 2019.

Disponível em: <https://integrada.minhabiblioteca.com.br/books/9786556900803/>

11 Bibliografia complementar

BANIN, Sérgio Luiz. **Python 3 - Conceitos e Aplicações - Uma Abordagem Didática [BV:MB]**. São Paulo: Érica, 2018.

Disponível em: <https://integrada.minhabiblioteca.com.br/books/9788536530253/>

Batista, M.D. C. [BV:MB]. **Data Mining**. Porto Alegre: SAGAH, 2021.

Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9786556900292/>

MORAIS, Izabelly. **Introdução a Big Data e Internet das Coisas (IOT) [BV:MB]**. Porto Alegre: SAGAH, 2018.

Disponível em: <https://integrada.minhabiblioteca.com.br/books/9788595027640/>

MUELLER, John Paul. **Aprendizado Profundo para Leigos [BV:MB]**. Rio de Janeiro: Alta Books, 2020.

Disponível em: <https://integrada.minhabiblioteca.com.br/books/9788550816982/>

PERKOVIC, Ljubomir. **Introdução à Computação Usando Python - Um Foco no Desenvolvimento de Aplicações [BV:MB]**. 1ª Ed. Rio de Janeiro: LTC, 2016.

Disponível em: <https://integrada.minhabiblioteca.com.br/books/9788521630937/>