

Aula 3

Prof. Felipe Alves



1

Introdução e Aplicações ao Big Data

Ao final deste módulo, você será capaz de reconhecer os conceitos e as aplicações de Big Data.

Arquitetura básica de Big Data

A complexidade que envolve o gerenciamento de todas as características do Big Data exige que tratemos sua arquitetura de modo específico, o que, mais uma vez, o diferencia dos sistemas de banco de dados tradicionais que teriam dificuldade em lidar com operações de dados em sistemas heterogêneos. Esses sistemas são chamados de **data lake**, que, literalmente, pode ser traduzido como “lago de dados”. Basicamente, trata-se de um enorme repositório de arquivos e objetos de dados. Portanto, as soluções da arquitetura de Big Data precisam ser eficientes para que possam produzir resultados com tempos de resposta aceitáveis. Os componentes da arquitetura de Big Data são:

Fontes de dados (data sources)



Armazenamento de dados (data storage)



Processamento em lote (batch processing)



Ingestão de mensagens (message ingestion)



Processamento de fluxo (stream processing)



Armazenamento de dados analíticos (analytical data store)




Análise e relatórios (analysis and reporting)



KPI

Os KPI são indicadores de desempenho que integram os painéis (dashboards). Esses indicadores podem ser de três tipos:



2 — Conceitos de IOT e Computação Distribuída

Ao final deste módulo, você será capaz de categorizar conceitos de Internet das Coisas e computação distribuída.

A Internet das Coisas (IoT) é a infraestrutura que viabiliza a conexão e comunicação por meio da Internet desses objetos remotos.

A IoT é uma tecnologia que aumenta as conexões entre pessoas, computadores e dispositivos eletrônicos – estes últimos são chamados de “coisas”. Trata-se de uma revolução, pois a IoT viabiliza a extensão da realidade física para além de limitações espaciais, como, por exemplo, o acompanhamento da saúde de pacientes em regiões de difícil acesso. Essa tecnologia nos fornece acesso a dados sobre o meio físico com grande nível de detalhes, os quais, posteriormente, podemos analisar, compreender e tomar as ações adequadas, para otimizar processos, corrigir problemas, detectar oportunidades de melhorias e aumentar o nosso conhecimento a respeito de um contexto.



Internet das Coisas (IoT).

Dados de fontes diferentes

Viabiliza que possamos verificar a **veracidade** dos dados, ou seja, o quão confiáveis eles são para representar o que está sendo observado.

Diferentes formatos

Podemos ter dados que são emitidos por diferentes sensores que retratam a **variedade** de representações do que estamos monitorando.

Frequência de geração dos dados

Os dados são enviados para a rede em uma **velocidade** característica da tecnologia que estamos aplicando.

— Computação Distribuída e IoT

A tecnologia de IoT consiste na coexistência colaborativa de quatro componentes:



Objetos físicos (ou "coisas")

Componentes eletrônicos e sensores responsáveis pela coleta de dados e aplicação de ações. Exemplo: termostatos usados para controlar a temperatura de um ambiente.



Computação

Faz o gerenciamento do ciclo de vida dos dados, desde a coleta e o armazenamento até o processamento dos dados.



Protocolos de comunicação

Viabilizam a troca dados via Internet entre os objetos físicos e outros sistemas.



Serviços

Provêm autenticação e gerenciamento de dispositivos, além de oferecer a infraestrutura.

Aspectos da computação distribuída

Distribuição e processamento

Distribuição de armazenamento e processamento de dados entre os nós da rede, para que a eficiência dos processos seja otimizada.

Transferência de dados e análises

A transferência de dados e as análises devem ser realizadas conforme necessário, pois diferentes níveis de processamentos podem ser realizados pelos nós da rede. Isso significa que o custo global de processamento e análise dos dados é minimizado, uma vez que os nós menos onerosos realizam pré-processamentos que reduzem o custo do processamento final dos nós mais caros da rede.

Tolerância a falhas

Outro princípio importante diz respeito à tolerância a falhas, pois é muito provável que haja intermitência da operação dos nós das redes, portanto a política de computação distribuída já deve estar preparada para reorganizar o fluxo de dados na rede, de maneira que possam ser roteados de um outro modo e que a rede continue em operação.

Otimização dos recursos computacionais da rede

Em especial, no caso da IoT, em que os dispositivos possuem uma restrição de recursos de memória e processamento, a computação distribuída trabalha com baixos níveis de consumo de energia.

Computação distribuída e Big Data

Em um projeto de Big Data, de modo geral, temos que coletar uma grande quantidade de dados, armazená-los, processá-los e analisá-los para detectar padrões relevantes que demandem, quando necessário, algum tipo de ação. Agora, quando aplicamos Big Data para IoT, precisamos tratar a complexidade das características intrínsecas dos seus componentes, ou seja, utilizar uma solução que dê suporte para o alto volume de dados e consiga se comunicar com os dispositivos. Mas qual solução seria essa?

A computação distribuída se torna a solução mais adequada no sentido de distribuir a computação para os nós da IoT.

Uma arquitetura básica de computação distribuída de IoT é composta pelas camadas de:

Computação em nuvem (cloud computing)



Computação em névoa (fog computing)



Computação de borda (edge computing)



Sensores e controladores



Computação em nuvem (cloud computing)



É a tecnologia que permite o uso remoto de recursos computacionais de software e hardware. Por exemplo, quando utilizamos repositórios na Internet para armazenar dados ou servidores de aplicação, estamos trabalhando com computação em nuvem. Essa camada é responsável por:


- processamento de Big Data;
- lógica de negócios;
- armazenamento de dados – mais conhecido como data warehousing.

Computação em névoa (fog computing)



É uma extensão da camada de nuvem que aproxima servidores aos dispositivos de IoT. Esses servidores podem colaborar entre si por meio de trocas de dados e realizar processamentos que vão otimizar a operação do sistema como um todo. Entre suas principais características, temos:

- processamento de Big Data;
- análise e redução de dados;
- controle de respostas;
- virtualização e padronização.




Computação de borda (edge computing)



Essa camada relaciona-se diretamente com os sensores e controladores que ficam na “borda” da arquitetura. Dessa forma, os dados podem ser armazenados e processados para, então, serem enviados à camada de névoa. Podemos destacar os seguintes aspectos dessa camada:

- processamento de grande volume de dados em tempo real.
- visualização de dados da fonte, ou seja, que vêm dos dispositivos eletrônicos.
- uso de computadores industriais que são específicos para trabalhar com determinados dispositivos eletrônicos.
- uso de sistemas integrados – também chamados de sistemas de bordo – que já vêm configurados nas placas.
- utilização de Gateways para interconectar os dispositivos com a rede por meio da conversão de protocolos e de sinais.
- sistema de armazenamento de microdados.



Sensores e controladores

São os dispositivos responsáveis por gerar os dados e, quando acionados, realizar ações. Por exemplo, em um sistema de irrigação, temos sensores que fazem o monitoramento da umidade do solo e controladores que fazem a irrigação até obter o nível adequado de umidade.

