

# Aula 4

HADOOP E ARMAZENAMENTO DE DADOS

Felipe Alves



# Objetivos

- Conhecer o framework Hadoop, destacando o armazenamento e o tratamento de grande massa de dados, para aplicações Big Data.

# Questão

- O Apache Hadoop é um framework para o armazenamento e processamento de Big Data;
- Ele possui ferramentas para armazenar e recuperar grandes volumes de dados distribuídos e para realizar o processamento distribuído, garantindo escalabilidade e disponibilidade e possibilitando a extração de conhecimento útil a partir de análises e cruzamentos desses dados;
- É indicado quando precisa-se de alto desempenho em processamento de grande volume de dados;
- Quais os benefícios iniciais que o Apache Hadoop pode trazer para sua organização?

# Desenvolvedores



**2005:** Doug Cutting e Michael J. Cafarella desenvolveu o Hadoop para dar suporte à distribuição do projeto do mecanismo de busca Nutch.


O projeto foi financiado pelo Yahoo.

**2006:** O Yahoo deu o projeto à Apache Software Foundation.





# Grandes usuários

- Indiscutivelmente a rede de mídia social mais popular do mundo, com mais de dois bilhões de usuários ativos mensais em todo o mundo, o Facebook armazena enormes quantidades de dados de usuários, tornando-se um enorme paraíso de dados;
- Em 2019 os Facebook nos Estados Unidos passou de 183 milhões de usuários;
- O Facebook está entre as 100 maiores empresas públicas do mundo, com um valor de mercado de aproximadamente US\$ 475 bilhões.




# As 60 maiores empresas segundo o InfoMoney

|                                                                                                              |                                                                                                              |                                                                                                              |                                                                                                              |                                                                                                                |                                                                                                                |                                                                                                                |                                                                                                                |                                                                                                                 |                                                                                                               |
|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------|
| 01<br><br>-3%<br>488.9 \$B  | 02<br><br>+11%<br>352.5 \$B | 03<br><br>+8%<br>298.1 \$B  | 04<br><br>+12%<br>291.3 \$B | 05<br><br>+10%<br>100.8 \$B  | 06<br><br>+13%<br>72.8 \$B  | 07<br><br>+5%<br>61.2 \$B   | 08<br><br>-4%<br>58.9 \$B   | 09<br><br>+4%<br>53.0 \$B    | 10<br><br>+2%<br>52.0 \$B  |
| 11<br><br>+9%<br>50.9 \$B   | 12<br><br>-9%<br>45.5 \$B   | 13<br><br>+5%<br>45.5 \$B   | 14<br><br>-5%<br>45.4 \$B   | 15<br><br>+15%<br>45.1 \$B  | 16<br><br>+11%<br>42.8 \$B  | 17<br><br>+12%<br>39.4 \$B  | 18<br><br>+9%<br>37.7 \$B   | 19<br><br>+7%<br>37.3 \$B    | 20<br><br>+11%<br>36.8 \$B |
| 21<br><br>+10%<br>34.9 \$B  | 22<br><br>+15%<br>34.7 \$B  | 23<br><br>+7%<br>33.2 \$B   | 24<br><br>+16%<br>30.1 \$B  | 25<br><br>+5%<br>27.1 \$B    | 26<br><br>+9%<br>26.7 \$B   | 27<br><br>+11%<br>26.7 \$B  | 28<br><br>+6%<br>24.3 \$B   | 29<br><br>+13%<br>23.5 \$B   | 30<br><br>+13%<br>23.0 \$B |
| 31<br><br>+3%<br>21.9 \$B   | 32<br><br>+13%<br>21.1 \$B  | 33<br><br>+6%<br>21.0 \$B   | 34<br><br>+9%<br>20.8 \$B   | 35<br><br>-2%<br>20.0 \$B   | 36<br><br>New<br>20.0 \$B   | 37<br><br>-30%<br>19.7 \$B  | 38<br><br>+10%<br>19.7 \$B  | 39<br><br>+8%<br>18.5 \$B    | 40<br><br>+3%<br>18.3 \$B  |
| 41<br><br>-10%<br>17.9 \$B | 42<br><br>+8%<br>17.8 \$B  | 43<br><br>+7%<br>17.4 \$B  | 44<br><br>+6%<br>17.3 \$B  | 45<br><br>+6%<br>17.3 \$B   | 46<br><br>-7%<br>17.1 \$B  | 47<br><br>+12%<br>17.1 \$B | 48<br><br>+2%<br>16.8 \$B  | 49<br><br>+9%<br>16.5 \$B   | 50<br><br>+9%<br>15.8 \$B |
| 51<br><br>-6%<br>15.5 \$B | 52<br><br>-1%<br>15.3 \$B | 53<br><br>+9%<br>14.8 \$B | 54<br><br>+5%<br>14.5 \$B | 55<br><br>+6%<br>14.5 \$B | 56<br><br>-3%<br>14.4 \$B | 57<br><br>+1%<br>14.4 \$B | 58<br><br>+7%<br>14.0 \$B | 59<br><br>+10%<br>13.9 \$B | 60<br><br>0%<br>13.6 \$B |

# Número de usuários do Facebook nos Estados Unidos de 2019 a 2028

(em milhões)



DOWNLOAD

PDF + XLS + PNG + PPT +

**Fonte**

- [Mostrar informações das fontes](#)
- [Mostrar informações da editora](#)
- [Utilize o serviço de pesquisa Ask Statista.](#)

**Data de lançamento**

Dezembro de 2024

**Região**

Estados Unidos

**Período de tempo da pesquisa**

2019 a 2028

**Propriedades especiais**

Usuários da internet que acessam sua conta do Facebook por meio de qualquer dispositivo pelo menos uma vez por mês.


**Notas complementares**



# 1. 81% afirmaram usar mídias sociais na estratégia de Marketing

Ainda tem alguma dúvida de que não dá mais para deixar de usar as redes sociais na sua estratégia de Marketing Digital? Embora esse número tenha caído um pouco com relação a 2022, em 2023, a atuação em redes sociais é a principal estratégia usada pelos profissionais de Marketing.


As estratégias de Marketing mais exploradas pelos times





### 3. Instagram se destaca com 88% de uso frequente

Entre as **estatísticas de redes sociais** presentes nos Panoramas, também vimos que redes sociais são uma estratégia praticamente unânime entre as empresas. Isto nos mais diversos segmentos e tamanhos — e 88% dos profissionais usam o Instagram com frequência.



# Histórico

2003

## The Google File System

Sanjay Ghemawat, Howard Gobioff, and Shun-Tak Leung  
Google\*



2004

## MapReduce: Simplified Data Processing on Large Clusters

Jeffrey Dean and Sanjay Ghemawat  
jeff@google.com, sanjay@google.com  
*Google, Inc.*



2006

## Bigtable: A Distributed Storage System for Structured Data

Fay Chang, Jeffrey Dean, Sanjay Ghemawat, Wilson C. Hsieh, Deborah A. Wallach,  
Mike Burrows, Tushar Chandra, Andrew Fikes, Robert E. Gruber  
{fay,jeff,sanjay,wilson,h,kerr,m3b,tushar,fikes,gruber}@google.com  
*Google, Inc.*



### Abstract

Bigtable is a distributed storage system for managing structured data that is designed to scale to a very large number of petabytes of data across thousands of commodity servers. Many projects at Google store data in Bigtable, including web indexing, Google Earth, and Google File Service. These applications place very different demands on Bigtable, both in terms of data size (from URLs to

achieved scalability and high performance, but Bigtable provides a different interface than such systems. Bigtable does not support a full relational data model; instead, it provides clients with a simple data model that supports dynamic control over data layout and format, and allows clients to reason about the locality properties of data represented in the underlying storage. Data is indexed using row and column names that can be arbitrary strings. Bigtable also treats data as uninterpreted strings.

# Evolução

Interesse ao longo do tempo ⓘ

Global · 2004 até o presente



<https://trends.google.com.br/explore?q=%2Fm%2F0fdjtq&date=all&geo=Worldwide>

# Evolução

Interesse por região ?

Região ▾




1 Israel

100




2 Tunísia

<1




3 Índia

<1




4 Marrocos

<1



5 Singapura

<1



Incluir regiões com baixo volume de pesquisa



Mostrando 1 a 5 de 41 regiões




# Hadoop

- O Apache Hadoop é um projeto de software de código aberto que pode ser usado para processar de modo eficiente grandes conjuntos de dados;
- Em vez de usar um grande computador para processar e armazenar os dados, o Hadoop permite o agrupamento de hardware padrão em clusters para analisar em paralelo grandes conjuntos de dados.

# Hadoop

- O Hadoop implementa o paradigma Map/Reduce, onde a aplicação é dividida em pequenos fragmentos, cada qual sendo executado em qualquer nó do cluster;
- Fornece também um Sistema de arquivo distribuído, Hadoop Distributed File System (HDFS);
- O HDFS armazena dados nos nós computacionais (compute nodes);
- O MapReduce e o HDFS foram criados de forma em que falhas nos nós são automaticamente tratadas pelo framework;
- Foi projetado para processamento em batch. Se precisa de análise em tempo real, usar o Spark


# Escalabilidade






# Cluster

- O **Master Node** supervisiona as duas principais peças funcionais que compõem o Hadoop: armazenamento de muitos dados (HDFS) e execução de cálculos paralelos em todos os dados (Map Reduce).
- O **Slave Node** compõe a maioria das máquinas e faz todo o trabalho de armazenar os dados e executar os cálculos. Cada Slave Node executa um daemon Data Node e Task Tracker que se comunica e recebe instruções de seus nós mestres. O Daemon TaskTracker é um slave do JobTracker, o DataNode daemon um slave do NameNode.



O cluster Hadoop possuem dois tipos de máquinas: Master Node e Slave Node.


## Hadoop Server Roles



# Ecossistema do Hadoop

- Existem vários aplicativos e mecanismos de execução no ecossistema do Hadoop, o que disponibiliza várias ferramentas compatíveis com as necessidades das suas cargas de trabalho de análise;
- O termo Hadoop comumente se refere ao projeto Apache Hadoop em si, que inclui o MapReduce (estrutura de execução), o YARN (gerente de recursos) e o HDFS (armazenamento distribuído);
- No entanto, também existem outros aplicativos e outras estruturas no ecossistema do Hadoop, como ferramentas que permitem consultas de baixa latência, GUIs para consultas interativas, várias interfaces (como SQL) e bancos de dados NoSQL distribuídos.

# Ecosystem Hadoop



# Componentes do ecossistema do Hadoop

- **Hadoop MapReduce** (será definido nos próximos slides)
  - **Mahout** - é uma API rápida, fácil e que permite aos desenvolvedores utilizar algoritmos complexos sem se preocupar com suas implementações
  - **Hive** - é um Data Warehouse para consulta e análise de dados. ele oferece uma interface semelhante a SQL para consulta de dados em diferentes bancos de dados e sistemas de arquivos integrados ao Hadoop
  - **Pig** - visa facilitar os desenvolvedores na manipulação de dados e realização de consultas no Hadoop. Através de uma linguagem própria, denominada Pig Latin, o Pig remove as dificuldades no uso da linguagem do MapReduce, com uma sintaxe simples, aumenta a produtividade.
- **Hadoop Yarn** (será definido nos próximos slides)
- **Hadoop HDFS** (será definido nos próximos slides)

# Componentes do ecossistema do Hadoop

- **Spark** - é um framework de código fonte aberto para computação distribuída. Provê uma interface para programação de clusters com paralelismo e tolerância a falhas
  - **Spark streaming** - é uma extensão da API principal do Spark que permite o processamento de fluxo escalável, de alto rendimento e tolerante a falhas de fluxos de dados ao vivo
  - **Spark SQL** - traz suporte nativo SQL ao Spark e agiliza o processo de consulta de dados armazenados tanto em RDDs (conjuntos de dados distribuídos do Spark) quanto em fontes externas
  - **Spark MLlib** - biblioteca de aprendizado de máquina escalável que consiste em algoritmos e utilitários de aprendizado comuns, incluindo classificação, regressão, clustering, filtragem colaborativa, redução de dimensionalidade, bem como primitivas de otimização subjacentes
  - **GraphX** - novo componente no Spark para gráficos e computação paralela de grafos. O GraphX estende o Spark RDD introduzindo uma nova abstração de Graph: um multigrafo direcionado com propriedades anexadas a cada vértice e aresta

# Componentes do ecossistema do Hadoop

- **Storm** - é um sistema de computação distribuída, tolerante a falhas e de software livre. Você pode usar o Storm para processar fluxos de dados em tempo real
- **Lucene** - A Apache desenvolveu uma API de nome Lucene que tem como utilidade recuperar informações em aplicações de arquivos
- **ZooKeeper** - é um servidor de código aberto para coordenação distribuída altamente confiável de aplicativos em nuvem
- **HBase** - é um banco de dados distribuído open-source orientado a coluna, modelado a partir do Google BigTable e escrito em Java. O Hbase tem fácil integração com o Hadoop, sendo assim, pode utilizar o MapReduce para distribuir o processamento dos dados, podendo processar facilmente vários terabytes de dados
- **Cassandra** - é um banco de dados distribuído NoSQL de código aberto confiável por milhares de empresas para escalabilidade e alta disponibilidade sem comprometer o desempenho. A escalabilidade linear e a tolerância a falhas comprovada em hardware comum ou infraestrutura em nuvem o tornam a plataforma perfeita para dados de missão crítica.
- **Flume** - é um software distribuído, confiável e disponível para coletar, agregar e mover com eficiência grandes quantidades de dados de log
- **Kafka** - tem como objetivo fornecer uma plataforma unificada, de alta capacidade e baixa latência para tratamento de dados em tempo real

# Componentes básicos - MapReduce

- O MapReduce foi criado pelo Google como uma solução para o processamento paralelo;
- É um modelo de programação para processamento de grandes volumes dados, da ordem de Terabytes ou Petabytes, por exemplo, executado paralelamente em clusters com um ou até milhares de nós;
- Possibilita a análise de grandes quantidades de dados com seus programas podendo ser escritos em diversas linguagens de programação, como JAVA e Python;
- É o principal algoritmo utilizado pela engine de processamento do Hadoop para distribuir um trabalho em um cluster


# Componentes básicos - MapReduce

- Processa grandes quantidades de dados e os separa em duas partes, organizando-as em pares de valores para processamento paralelo, aumentando velocidade e confiabilidade de um cluster, retornando soluções rapidamente e com maior confiabilidade;
- Ao executar um job, o MapReduce divide o mesmo em duas tarefas, a Map e a Reduce;
- O YARN (Yet Another Resource Negotiator) se responsabiliza pelo agendamento das tarefas nos nós e também no tratamento de falhas.




# Componentes básicos - MapReduce

- Na função Map os dados de entrada são separados em pares de valores do tipo chave-valor onde é feito um sort, agrupando pelos valores chave onde essa saída da função será as entradas para a função reduce;
- Os resultados são coletados pela função Reduce e combinados para que se possa resolver um problema maior para o nó principal;
- Cada reduce pega a partição relevante das máquinas onde os maps executaram, e então escrevem a saída no HDFS – (Hadoop Distributed File System);
- O reduce é capaz de coletar os dados de todos os maps para as chaves e os combinar para resolver o problema




# Componentes básicos - HDFS

- O Hadoop Distributed File System (HDFS) é um sistema de arquivos distribuídos, criado para ser altamente tolerante à falha e ser implementado em hardware de baixo custo;
- Provê alta taxa de transferência de dados no acesso a dados da aplicação e se comporta muito bem com grande quantidade de dados;
- No HDFS há uma arquitetura master/slave onde existe o NameNode como o servidor principal (master), o qual gerencia o sistema de arquivos de espaço de nome (namespace) e regula o acesso aos arquivos por clientes




# Componentes básicos - HDFS

- Há também os DataNodes, geralmente um por nó em um cluster, que gerencia o armazenamento em cada nó em que eles são executados;
- HDFS expõe o arquivo de espaço de nomes de sistema para serem armazenados em arquivos. Internamente, um arquivo é dividido em um ou mais blocos e esses blocos são armazenados em um conjunto de DataNodes.




# Componentes básicos - HDFS

- O NameNode executa operações de sistema de arquivos de espaço de nomes do tipo abrir, fechar e renomear arquivos e diretórios. Também determina o mapeamento de blocos para os DataNodes.
- Os DataNodes são responsáveis por atender requisições de leitura e escrita vindas do sistema de arquivo dos clientes.
- Os DataNodes também realizam a criação, exclusão e replicação por intermédio do NameNode.



# Componentes básicos - HDFS

- FsImage é um arquivo armazenado no sistema de arquivos do SO que contém a estrutura de diretórios completa (namespace) do HDFS



# Componentes básicos - YARN

- O YARN é uma tecnologia de gerenciamento de cluster que é atualmente caracterizado como um sistema operacional distribuído para aplicações de big data que "roda processos em um cluster de maneira similar ao modo como um sistema operacional roda processos em um computador".

# Componentes básicos - Hive

- O Hive é uma infraestrutura de armazenamento de dados que trabalha sobre o Apache Hadoop criado para facilitar a manipulação de dados para os familiarizados com a linguagem SQL.
- Com uma sintaxe muito semelhante, o Hive possibilita a realização de consultas diversas.
- Essas consultas são então divididas em tarefas Map/Reduce e são executadas no cluster.

# Conclusão: O Ecossistema Hadoop

## O Alicerce da Inteligência de Dados

O Hadoop deixou de ser apenas uma ferramenta de armazenamento para se tornar a **espinha dorsal da estratégia de Big Data** moderno, permitindo que empresas transformem dados brutos em ativos estratégicos com custo reduzido.

- **Escalabilidade Horizontal:** Capacidade de crescer conforme a demanda, adicionando nós comuns sem interrupção.
- **Resiliência e Tolerância a Falhas:** Replicação nativa de dados (HDFS) que garante a continuidade do negócio mesmo em falhas de hardware.
- **Processamento Distribuído:** Otimização de tempo ao levar o processamento até onde o dado reside, e não o contrário.



# Conclusão: Possibilidades de Uso e Aplicações Reais

| Setor               | Aplicação Prática                                                       |
|---------------------|-------------------------------------------------------------------------|
| <b>Financeiro</b>   | Detecção de fraudes em tempo real e análise de risco de crédito.        |
| <b>Varejo</b>       | Motores de recomendação personalizados e previsão de estoque.           |
| <b>Saúde</b>        | Análise de grandes volumes de exames e sequenciamento genético.         |
| <b>Marketing</b>    | Análise de sentimento em redes sociais e segmentação de hiper-público.  |
| <b>TI &amp; IoT</b> | Monitoramento de logs de sistemas e processamento de dados de sensores. |