Data Warehouse
Data Mart
Data Lake
Data lakehouse

Data Warehouse (Armazém de Dados)

O que é: Um repositório centralizado de dados estruturados, usados principalmente para análise e geração de relatórios.

Características:

- Dados organizados em tabelas e colunas (como em bancos relacionais).
- Ideal para BI (Business Intelligence).
- Alta performance em consultas analíticas.

Exemplo de uso: Relatórios financeiros, dashboards de vendas.

Data Mart
(Mercado de Dados)

O que é: Um subconjunto de um Data Warehouse, focado em um departamento ou área específica (como vendas, marketing, etc).

Características:

- Mais específico e enxuto que um Data Warehouse.
- Facilita o acesso rápido e direto para equipes específicas.

Exemplo de uso: Data Mart de RH com dados só de funcionários e folha de pagamento.

Data Lake
(Lago de Dados)

O que é: Um grande repositório que armazena dados em seu formato bruto, estruturados e não estruturados.

Características:

- Pode conter arquivos CSV, imagens, vídeos, logs, etc.
- Flexível e escalável, mas exige mais processamento para análise.

Exemplo de uso: Armazenar dados de sensores IoT, cliques de usuários, áudios para análise posterior.

Data Lakehouse (Mistura de Lago e Armazém)

O que é: Uma arquitetura que combina o melhor do Data Lake e do Data Warehouse.

Características:

- Armazena dados brutos como o Data Lake.
- Permite análises rápidas como um Data Warehouse.
- Usa tecnologias que suportam dados estruturados e não estruturados.

Exemplo de uso: Plataforma única para análise de dados em tempo real e dados históricos, como o Delta Lake (Databricks).

Comparação

Característica	Data Warehouse	Data Mart	Data Lake	Data Lakehouse
Tipo de dado	Estruturado	Estruturado	Estruturado, semi e não estruturado	Todos os tipos (estruturado e não estruturado)
Objetivo principal	Análise e BI corporativo	Análise de áreas específicas	Armazenamento bruto e flexível de dados	Análise flexível com performance de BI
Escopo	Amplo (toda a empresa)	Restrito (área ou departamento)	Muito amplo (pode ser toda a empresa)	Amplo, porém com arquitetura unificada
Formato de armazenamento	Tabelas relacionais (SQL)	Tabelas relacionais (SQL)	Arquivos (JSON, CSV, logs, imagens, etc.)	Mistura de tabelas e arquivos
Facilidade de análise	Alta	Alta	Baixa (requer processamento)	Alta
Performance em consultas	Alta	Alta	Baixa a média (depende da estrutura)	Alta
Custo	Alto (infraestrutura e manutenção)	Médio a alto	Mais baixo (armazenamento barato)	Equilibrado
Exemplos de uso	Relatórios financeiros, BI geral	Dashboard de vendas, análise de RH	Armazenar logs, vídeos, dados de sensores	Análise de dados em tempo real + históricos

Business Intelligence

BI – *Business Intelligence*, ou seja, ***INTELIGÊNCIA <u>DOS</u> NEGÓCIOS***

ou alternativamente ***INTELIGÊNCIA <u>NOS</u> NEGÓCIOS***.

Infra-estrutura tecnológica e organizacional para o suporte à tomada de decisões, conduzindo a decisões ***de melhor qualidade*** e ***no momento exato***.

Objetivos

Tomada de decisões – decisões ***melhores*** e ***no momento exato***.

Maior grau de abstração – ***dados*** → ***informações*** → ***conhecimento***.

Maior racionalidade nas atividades de gerenciamento.

O ciclo de atividades

BI se caracteriza pela interação ordenada de quatro processos: ***análise***, ***entendimento***, ***ação*** e ***monitoramento***.

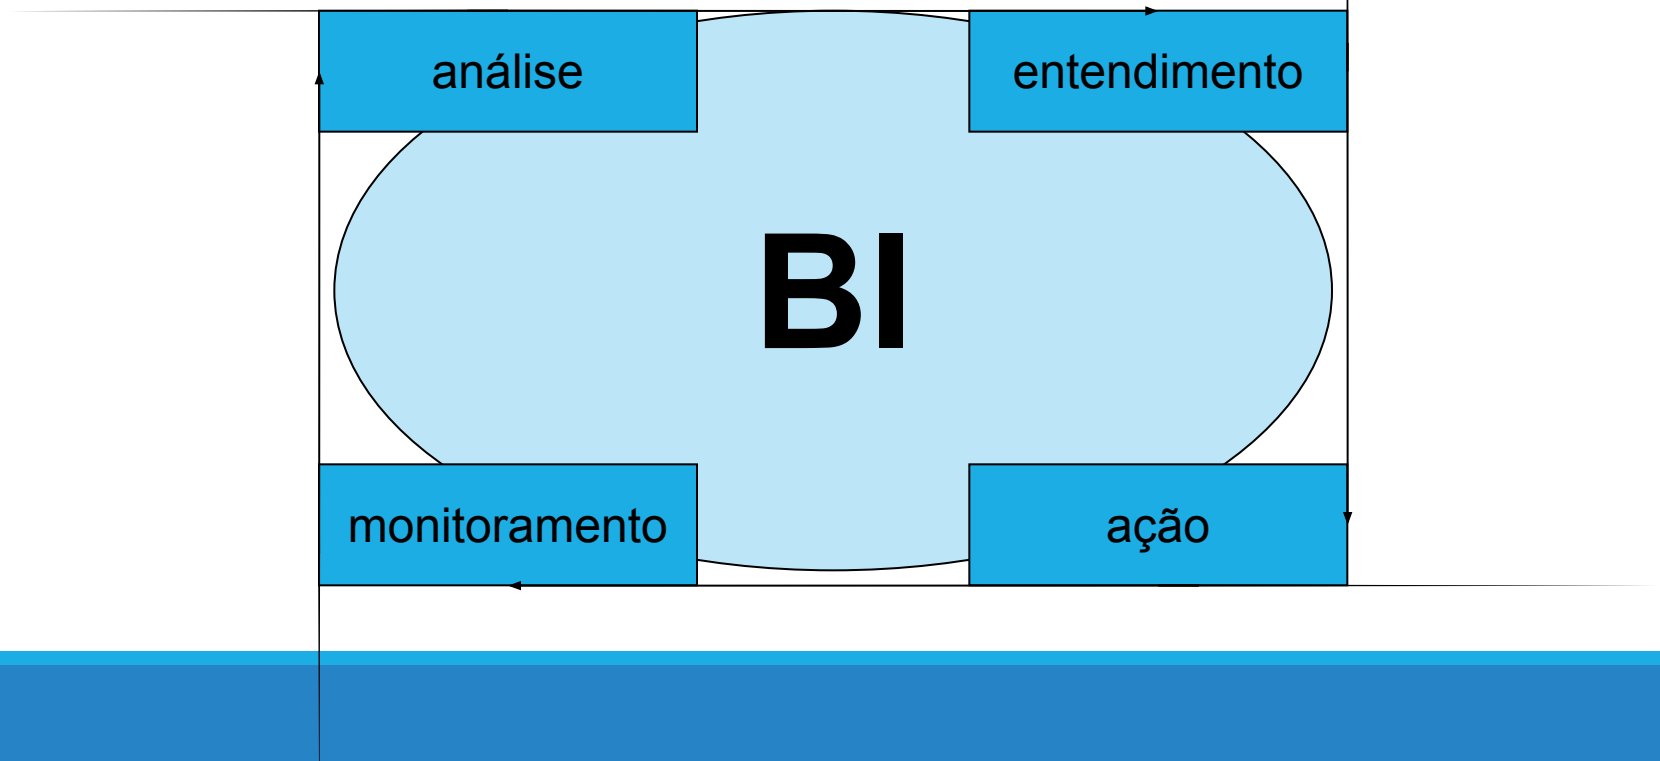

Análise

Métodos e processos que têm por objetivo a formulação de ***modelos*** e ***visões*** dos sistemas que são os objetos de negócios.

Esses modelos e visões são a base para o entendimento dos processos relevantes, e fundamentam todas as outras atividades relativas a BI.

Entendimento

Percepção de aspectos chave dos sistemas que são objetos de negócios, que podem ser controlados e modificados para melhorar a eficiência e a eficácia dos processos.

- **Eficiência**: desenvolver processos com mínimo consumo de recursos. “Foco no **como** fazer.”.
- **Eficácia**: identificar corretamente quais processos desenvolver para atingir determinados objetivos. “Foco no **o que** deve ser feito”.

Entendimento: exemplo

Uma rede varejista (ex.:supermercados) apresenta uma grande disparidade de lucratividade em suas lojas.

A alta gerência poderia **se concentrar nas lojas de baixa lucratividade** para procurar entender o que ocorre de errado nessas lojas, mas um bom ***entendimento*** do sistema, que é objeto dos negócios dessa empresa, pode indicar como ação mais adequada **se concentrar nas lojas de *alta* lucratividade**, para procurar entender o que ocorre nessas lojas que deve ser imitado por todas as outras.

Ação

Tendo formulado um modelo ou visão de um sistema e entendido seus problemas, dois passos conjugados devem ocorrer: ***decisão*** e ***ação***.

- A **decisão** indica o que deve ser feito – é o resultado direto e imediato da análise e do entendimento.
- A **ação** tem poder transformador e confere utilidade à decisão.

Monitoramento

A ação gera resultados, que precisam ser avaliados e comparados com os resultados esperados.
O ***monitoramento*** fecha o ciclo de atividades de BI, permitindo avaliar os resultados de ações e **levando a um novo ciclo** que se inicia com um processo de análise do sistema que deve ter sido transformado pelas ações anteriores.

Facilitadores

1. Tecnologia, em especial, tecnologia de informação.
2. Disponibilidade de dados.
3. Infraestrutura de comunicação e redes de computadores.
4. Padronização de processos de interação para compartilhamento de conhecimento.
5. Software especializado para BI.
6. Recursos humanos capacitados.
7. Cultura organizacional adequada.

Análise multidimensional

Ao analisar um conjunto de dados de forma agregada, muitos detalhes permanecem invisíveis.

A análise dimensional trata os dados agregados como *projeções* de um hiper-cubo, mas também possibilita "visualizar" o hiper-cubo de maneira integral.

Esses conceitos são explicados mais facilmente através de um exemplo.

Análise multidimensional

Exemplo: dados de vendas por semestre, produto e cidade – representação gráfica do cubo:

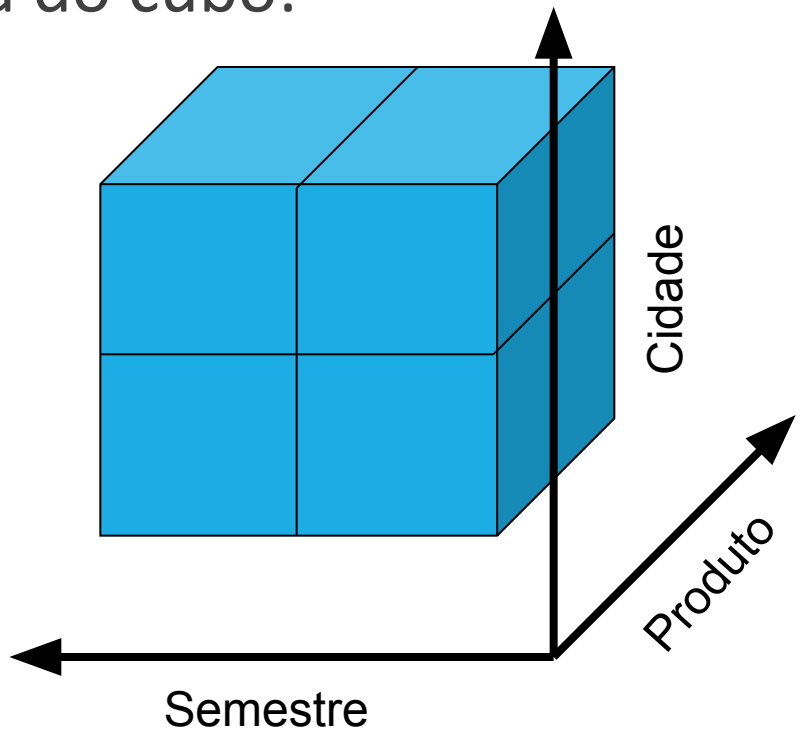

Análise multidimensional

Exemplo: dados de vendas por semestre, por produto e por cidade – os mesmos dados apresentados de forma mais detalhada, revelando o "interior do cubo":

Semestre	***Produto***	***Cidade***	***Valor***
Primeiro	Banana	Curitiba	3.000,00
		Salvador	1.000,00
	Laranja	Curitiba	4.000,00
		Salvador	8.000,00
Segundo	Banana	Curitiba	6.000,00
		Salvador	6.000,00
	Laranja	Curitiba	3.000,00
		Salvador	1.000,00

Análise dimensional

Exemplo: dados de vendas por semestre, por produto e por cidade:

Semestre	***Vendas***
Primeiro	16.000,00
Segundo	16.000,00

Produto	***Vendas***
Banana	16.000,00
Laranja	16.000,00

Cidade	***Vendas***
Curitiba	16.000,00
Salvador	16.000,00

Análise multidimensional

A análise multidimensional revela aspectos que podem ser úteis a respeito dos dados, como por exemplo **características de sazonalidade e regionalização**.

A organização multidimensional de dados é natural e intuitiva, permitindo construir bons modelos para representar informações a respeito dos sistemas analisados.

OLAP - On-line Analytical Processing

OLAP é a sigla em inglês para ***processamento online analítico*** *(online analytical processing).*
Os sistemas para OLAP permitem pesquisar os dados de um banco de dados de maneiras diversificadas e flexíveis.

Conceitualmente, esses dados devem ser organizados em ***dimensões*** (os eixos sobre os quais é construído o hiper-cubo) e ***valores*** (os valores que “preenchem” o hiper-cubo).

OLAP

refere-se a um conjunto de ferramentas voltadas para o acesso e análise *ad-hoc* de dados;

- seu objetivo final é transformar dados em informações capazes de dar suporte a decisões gerenciais de forma amigável e flexível ao usuário em tempo hábil.

OLAP

Multi-dimensionalidade

É o conceito chave da análise feita através de ferramentas OLAP. Neste tipo de análise, os dados são modelados em uma estrutura conhecida como cubo que nos permite observar vários assuntos (dimensões) para uma mesma massa de dados.

Veja a figura a seguir:

OLAP

Multidimensional

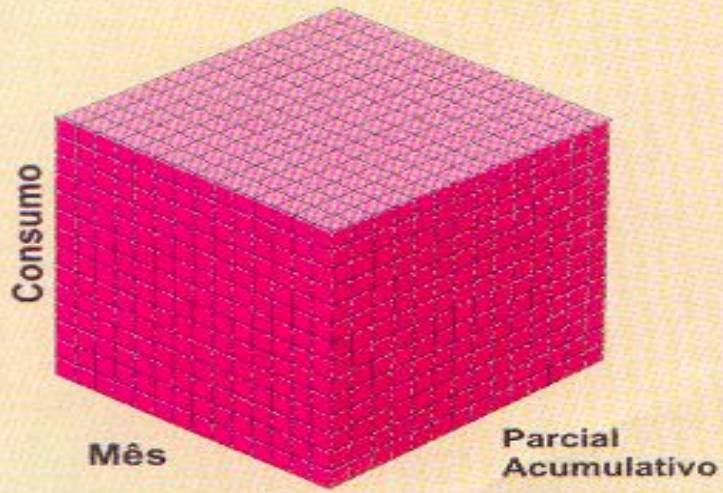

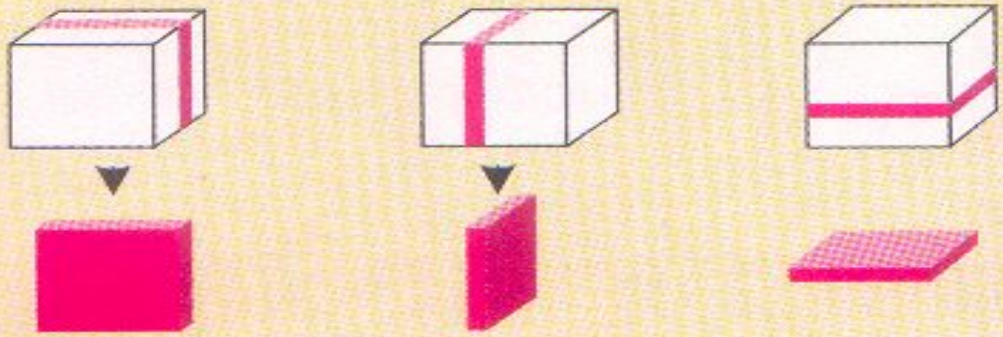

KWh	Parcial	Acumulado
Janeiro	180.000.000	180.000.000
Fevereiro	210.000.000	390.000.000
Março	235.000.000	625.000.000
Abril	220.000.000	845.000.000

OLAP

As operações de OLAP podem ser caracterizadas genericamente em:

- **Agregação, sumarização e projeção**, que sumarizam os valores e tipicamente reduzem a dimensionalidade do hiper-cubo.
- **Detalhamento**, que é o inverso das operações anteriores.
- **Rotação**, em que a variável que caracteriza os valores do hiper-cubo troca de lugar com uma das dimensões (no nosso exemplo, poderíamos ter uma rotação em que as vendas passassem a ser uma dimensão e as cidades passassem a ser os valores.
- Nesse caso faria sentido consultar nomes de cidades por semestre, o produto e uma faixa de valores monetários.

OLAP

Existem duas formas básicas de implementar sistemas para OLAP:

- Utilizando matrizes esparsas (***MOLAP*** – OLAP **multidimensional**). Isso permite uma implementação mais fiel ao modelo conceitual, porém mais complexa de manipular.

- Utilizando a infra-estrutura já existente para bancos de dados relacionais (***ROLAP*** – OLAP **relacional**). Embora mais difícil de entender como implementação de OLAP, permite seguir em frente a partir da tecnologia já existente para manipulação de bancos de dados.

OLAP

Multidimensional

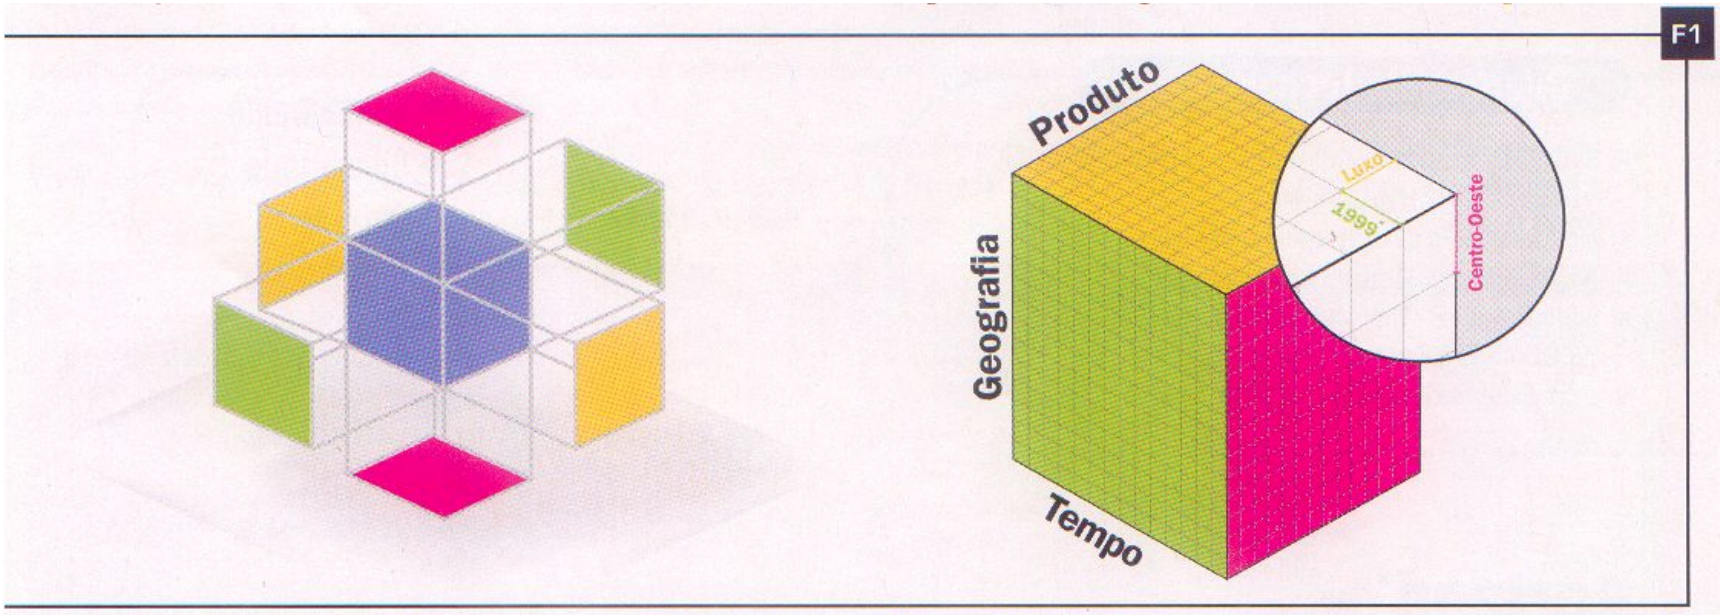

Características de uma Ferramenta OLAP

Principais característica:

- Rapidez de cálculo e acesso (grande volume de dados e consultas *ad-hoc*) ;
- Capacidade de análise avançada (média, média ponderada, normalização, ordenação acumulada no tempo;
- Flexibilidade (visualização, análise e interface);
- Suporte a múltiplos usuários.

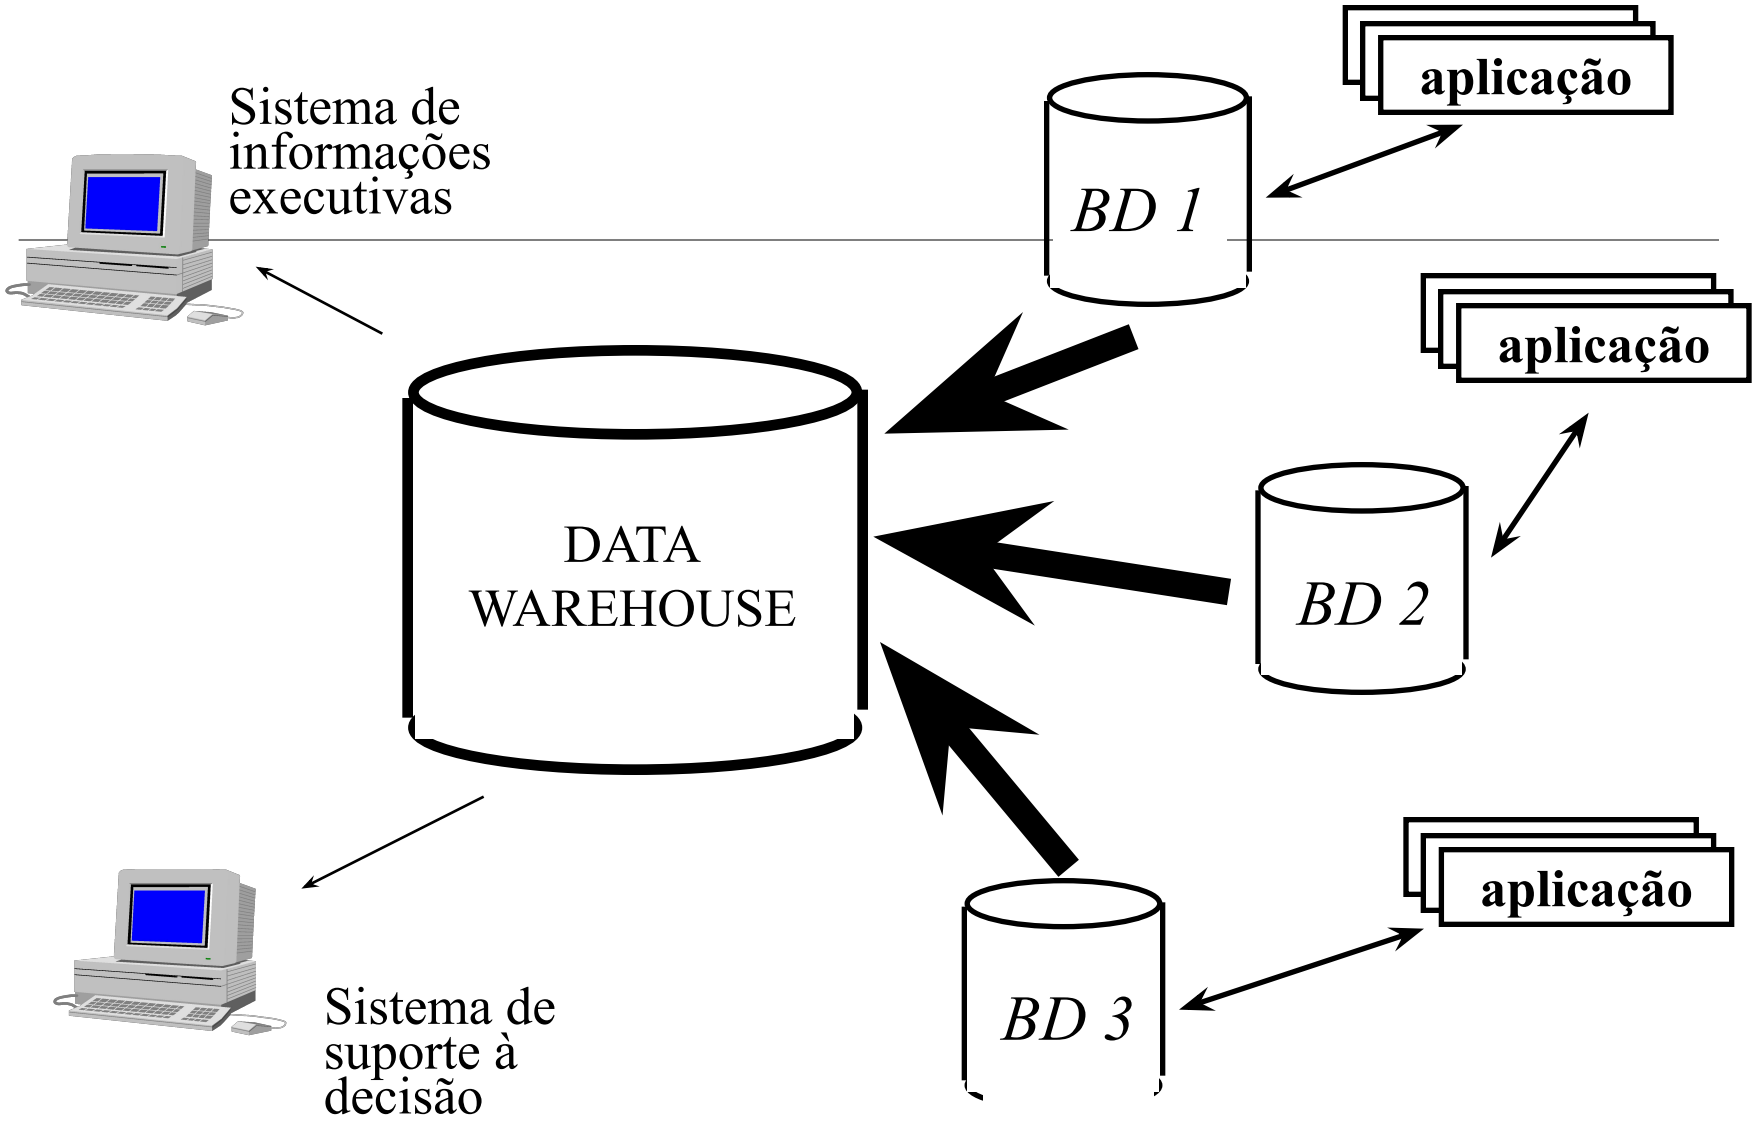
Sistema de informações executivas
aplicação
BD 1
aplicação
DATA WAREHOUSE
BD 2
aplicação
BD 3
Sistema de suporte à decisão

Oportunidades de uso

Perguntas fundamentais:

- ***Onde*** utilizar BI?
- ***Quem*** utilizará BI?
- ***Quais informações*** devem participar do modelo de BI?

Onde?

O que está funcionando bem?

O que está funcionando mal?

O que está consumindo muitos recursos?

O que está consumindo muito tempo?

Onde podem existir oportunidades não aproveitadas?

Onde estão sendo tomadas decisões ruins?

Onde estão sendo tomadas decisões boas?

Quem?

Regra heurística básica: identifique o grau hierárquico relativo de seus usuários em potencial.

- Posições **hierárquicas mais baixas** – dados específicos, detalhados, altamente especializados e de apoio as atividades operacionais.

- Posições hierárquicas mais altas – dados gerais, sumarizados e de apoio as atividades gerenciais.

Quais informações?

Sequência ideal:

1. Identifique os valores.
2. Classifique os valores como sendo ***de obtenção direta*** (por exemplo por mensuração ou observação) ou ***de obtenção indireta*** (por exemplo através de cálculos e equações).
3. Identifique as medidas que colocarão os valores em um contexto.
4. Defina o grau de detalhamento necessário para valores e dimensões.

Quais informações?

Com as dimensões e valores em mãos, é possível identificar ***áreas de oportunidades***, que são grupamentos de valores e dimensões que caracterizam sistemas (ou seja, hiper-cubos multidimensionais) relativamente independentes que podem servir de apoio à tomada de decisões.

Quais informações?

As áreas de oportunidade podem ser ordenadas segundo diferentes critérios. Dois critérios básicos são ***impacto potencial*** e ***dificuldade de operacionalização***.

Com base por exemplo nesses dois critérios podem ser construídos ***mapas de interesse*** que indicarão os sistemas prioritários para desenvolvimento.

Quais informações?

Os critérios de ordenação das áreas de oportunidade, se necessário, podem ser detalhados.
Por exemplo, o ***impacto potencial*** pode ser desmembrado em ***potencial para gerar ações concretas*** e ***mensurabilidade objetiva dos resultados***, e a ***dificuldade de operacionalização*** pode ser desmembrada em ***dificuldade para obtenção de dados*** e ***complexidade do modelo matemático***.

Conclusão

Business Intelligence:

- Conjunto de práticas organizacionais que viabilizam a tomada de decisões com grande eficiência e eficácia, e no momento exato.
- Formulação e implementação de BI se tornou possível graças à disponibilidade de recursos computacionais e de gerenciamento de informações (por exemplo OLAP).