



Big Data Analytics



Prof.: Felipe Alves



Big Data Analytics:

- Estamos imersos em dados: redes sociais, sensores, compras online, etc.
- Termos comuns: Ciência de Dados, Business Analytics, IA, Machine Learning.
- Big Data é a base para tudo isso.
- Diferenciar conceitos é essencial para aplicar corretamente as técnicas.

Exemplo:

Imagine que cada curtida no Instagram, cada clique em um site ou cada transação bancária gera dados. Como transformamos isso em conhecimento útil?

Propósito e Objetivos

Compreender o processo de KDD (Knowledge Discovery in Databases).

Aplicar algoritmos com Scikit-Learn (ML tradicional).

Aplicar redes neurais com TensorFlow (Deep Learning).

Por que Big Data Analytics é importante?

- Detectar fraudes bancárias
- Recomendação de filmes (Netflix)
- Diagnóstico de doenças com IA
- Otimização de logística (Amazon)

KDD: Conhecimento a partir de Dados

Etapas do KDD:

1. Seleção – escolha dos dados relevantes
2. Pré-processamento – limpeza e formatação
3. Transformação – padronização, normalização
4. Mineração de dados – aplicação de algoritmos
5. Interpretação/Avaliação – entendimento dos resultados

Exemplo prático:

Para prever evasão de clientes (Churn), selecionamos dados de comportamento, limpamos valores ausentes, transformamos variáveis categóricas e aplicamos um modelo de classificação.

Motivação: Por que isso é importante?

Vivemos na era dos dados em excesso. Tomamos decisões com base em dados a todo instante — empresas, governos, você!



O que isso tem a ver com IA?

Com o avanço tecnológico, os dados começaram a ser produzidos em Volume, Variedade, Velocidade, Veracidade e Valor → o famoso conceito dos 5 Vs do Big Data.

Breve Histórico da Web e Big Data

Era	Características
Web 1.0	Leitura: apenas consumo de conteúdo.
Web 2.0	Escrita: usuários também produzem dados (redes sociais, blogs).
Web 3.0	Hiperpersonalização: algoritmos que usam Big Data para prever preferências.

💡 A explosão de dados gerou a **necessidade de ferramentas para analisá-los**. É aí que entra a Ciência de Dados.

O que é Inteligência Artificial?

Segundo Russell e Norvig:

“É o campo que busca criar sistemas que imitem a capacidade humana de raciocinar, resolver problemas e aprender.”



Existem dois tipos principais:

- IA Simbólica: baseada em regras e lógica.
 - Ex: Se temperatura $> 38^{\circ}\text{C}$ $\rightarrow$ febre
- IA Subsimbolica (ou connexionista): baseada em redes neurais.
 - Ex: Reconhecimento de imagem com redes neurais profundas.

Aprendizado de Máquina (Machine Learning)

Método de fazer com que máquinas aprendam com dados.



Tipos de aprendizado:

1. Supervisionado – Dados rotulados (ex: prever se cliente vai sair)
2. Não supervisionado – Dados sem rótulo (ex: agrupar clientes por perfil)
3. Semissupervisionado – Apenas parte dos dados tem rótulo
4. Por Reforço – Agente aprende com tentativa e erro

Técnicas Populares

Técnica	Tipo	Exemplo
Classificação	Supervisionado	Prever se cliente vai cancelar (churn)
Regressão	Supervisionado	Prever valor de aluguel
Agrupamento	Não supervisionado	Agrupar clientes por perfil de compra

Da Web à Inteligência Artificial

A evolução da web e o crescimento do volume de dados abriu espaço para a IA e a ciência de dados.

Big Data Analytics permite encontrar padrões em meio ao caos.

Com ferramentas como Scikit-Learn e TensorFlow, conseguimos aplicar isso na prática.

Big Data e o Boom da Inteligência Artificial

Origem da IA

- Surgiu nos anos 1950, antes da internet.
- Inicialmente rudimentar e com pouco investimento prático.

Evolução com a Web

- A Web 2.0 e o boom tecnológico de 2007 impulsionaram a geração de grandes volumes de dados.
- IA passou a ser valorizada graças à disponibilidade de dados massivos e variados.

Florescimento da IA

- Novos problemas no ciberespaço e sociedade conectada impulsionaram pesquisas em IA.
- Avanços tecnológicos tornaram agentes mais eficazes e inteligentes.





O Papel da Ciência de Dados

Atua na análise de problemas de negócio com apoio de:

- Aprendizado de máquina (Machine Learning)
- Mineração de dados

Identifica padrões ocultos nos dados.


Permite adaptação dos sistemas ao ambiente organizacional.

Contribui diretamente para a consolidação da IA no mercado.

De Dados a Sabedoria: DIC-S

Conceito	Definição
Dado	Valor isolado sem contexto (ex: 38)
Informação	Dado contextualizado (ex: 38°C = temperatura corporal)
Conhecimento	Padrões descobertos a partir de várias informações e contextos
Sabedoria	Aplicação do conhecimento em uma ação prática (ex: prescrição médica)

Dados – Informação – Conhecimento – Sabedoria



O que é um Sistema de Informação?

- Conjunto de componentes que processam dados e fornecem informações úteis.
- Ex: Sistema hospitalar que coleta dados, armazena e analisa informações de pacientes.



Mineração de Dados vs KDD



Mineração de Dados

- Parte central do processo, mas não é o todo.



KDD (Knowledge Discovery in Databases)

- Processo completo para extrair conhecimento útil de grandes volumes de dados.
- Envolve várias etapas interdependentes.



Etapas do Processo KDD

Etapa	Descrição
1. Coleta de dados	Captura de dados brutos de diferentes fontes.
2. Seleção	Escolha de atributos relevantes para o problema.
3. Pré-processamento	Limpeza, tratamento de dados faltantes e integração.
4. Transformação	Normalização, redução de dimensionalidade, etc.
5. Mineração de dados	Aplicação de algoritmos de aprendizado de máquina.
6. Avaliação e apresentação	Análise da eficácia do modelo com métricas e visualizações.



CRISP-DM: O KDD da Indústria



Etapas do CRISP-DM

1. Entendimento do Negócio
2. Entendimento dos Dados
3. Preparação dos Dados
4. Modelagem
5. Avaliação
6. Implantação



Comparativo: KDD vs CRISP-DM

Etapas CRISP-DM

Equivalentes no KDD

Preparação dos Dados

Seleção, Pré-processamento, Transformação

Modelagem

Mineração de dados

Avaliação

Avaliação e Apresentação

Entendimento do Negócio/Dados

Substituem a Coleta de Dados

Implantação

Não está presente no KDD

O que é Aprendizado Profundo?

- Um ramo do Aprendizado de Máquina que atua na etapa de modelagem do processo CRISP-DM (modelagem de dados).
- Utiliza múltiplas camadas de processamento (lineares e não lineares) para representar dados complexos em formatos que a máquina pode compreender, como vetores, matrizes e séries temporais.
- Com TensorFlow, é possível construir e treinar redes neurais profundas de maneira eficiente e escalável.



Por que usar Aprendizado Profundo?

- Elimina a necessidade de pré-processamento manual e geração de características, já que essas tarefas são embutidas nas camadas ocultas do modelo.
- Baseia-se em redes neurais artificiais, que são grafos com nós interconectados que simulam o funcionamento dos neurônios humanos.



Como funcionam as redes neurais?

Cada camada aprende uma abstração dos dados.

- Exemplo com imagens:
 - Camada 1: detecta linhas
 - Camada 2: detecta formas básicas como círculos
 - Camada 3: detecta combinações (ex: rostos, objetos)





IA Simbólica vs IA Subsimbólica

IA Simbólica:

- Aprendizado baseado em regras, lógica, representações explícitas

IA Subsimbólica:

- Aprendizado direto dos dados e da experiência
- Redes neurais fazem parte da IA subsimbólica
- Dispensam etapas manuais de pré-processamento


Histórico: Perceptron

Criado por Frank Rosenblatt (1958)

Primeira rede neural artificial com entradas, saídas e função de ativação

Serve como classificador linear

Conjunto de perceptrons → forma uma rede neural



Tipos de Redes Neurais



1. CNN (Convolutional Neural Network)

- Especializadas em processamento de imagens
- Utilizam filtros convolucionais (matrizes que percorrem a imagem)
- Invariância espacial: detectam padrões mesmo se deslocados na imagem
- Autonomia elevada: aprendem os filtros automaticamente

Tipos de Redes Neurais



2. RNN (Recurrent Neural Network)

- Usadas em dados sequenciais ou temporais
- Possuem ciclos em sua estrutura, permitindo memória interna
- Exemplo: LSTM (Long Short-Term Memory)
 - Criada por Hochreiter e Schmidhuber (1997)
 - Utiliza gates de esquecimento para evitar:
 - Desaparecimento do gradiente (vanishing gradient)
 - Explosão do gradiente (exploding gradient)



TensorFlow e Deep Learning

TensorFlow é uma das principais bibliotecas para desenvolver modelos de aprendizado profundo.

Permite trabalhar com:

- CNNs para reconhecimento de imagem
- RNNs/LSTM para séries temporais e linguagem natural
- Redes profundas customizadas para diversos problemas (previsão, classificação, regressão etc.)



Considerações Finais



O que é a Inteligência Artificial (IA)?

- A IA busca simular comportamentos humanos, como:
 - Raciocínio lógico
 - Aprendizado com experiências passadas
 - Adaptação a novas situações
- O objetivo é que algoritmos consigam resolver problemas inéditos, mas semelhantes aos que já enfrentaram.



Por que a IA voltou a crescer?

Após um período chamado de "inverno da IA", a área foi impulsionada por:

- Aumento massivo de dados gerados por smartphones e dispositivos conectados
- Evolução das infraestruturas computacionais e redes colaborativas
- Necessidade crescente de soluções inteligentes em tempo real

Estratégias para simular o pensamento humano

- A IA se desenvolveu com diversas abordagens, como:
 - IA simbólica (baseada em regras e lógica)
 - IA subsimbólica (baseada em dados e aprendizado, como redes neurais)
- Cada abordagem resolve tipos diferentes de problemas, assim como o cérebro humano utiliza estratégias diferentes para aprender.



O papel das redes neurais

- Redes neurais artificiais são:
 - Capazes de abstrair informações complexas
 - Capazes de aprender sozinhas com os dados brutos, sem necessidade de pré-processamento manual
 - Fundamentais para técnicas como aprendizado profundo (Deep Learning)



O processo de KDD (Knowledge Discovery in Databases)

Para que um modelo de IA tenha sucesso, é essencial:

- Seguir um processo estruturado, como o KDD
- Esse processo inclui seis etapas para coletar, preparar, transformar, modelar e interpretar dados

O KDD é o caminho seguro para extrair padrões relevantes e obter resultados úteis com IA



Conclusão

A combinação entre grandes volumes de dados, algoritmos sofisticados e poder computacional tornou possível que modelos inteligentes, como redes neurais profundas, aprendessem e generalizassem comportamentos complexos, com impacto direto em áreas como saúde, finanças, transporte, agricultura, entre outras.

O aprendizado profundo com TensorFlow é uma das ferramentas mais poderosas nessa jornada, e seu uso consciente e estratégico é o que transforma dados em conhecimento e informações em decisões inteligentes.