REVISÃO – SIMULADO 1

TÓPICOS DE BIGDATA EM PYTHON

Prof. Felipe Alves

BIG DATA

VISÃO GERAL

Big Data refere-se ao processamento de grandes volumes de dados

Vai além das ferramentas tradicionais

Base para análise avançada e tomada de decisão

BIG DATA – CARACTERÍSTICAS (5 VS)

- Volume: grande quantidade de dados
- Velocidade: rapidez no processamento
- Variedade: múltiplos formatos
- Veracidade: qualidade dos dados
- Valor: geração de insights úteis

IOT – CONCEITO

Internet das Coisas conecta dispositivos ao ambiente digital

Permite coleta contínua de dados do mundo real

IOT – APLICAÇÃO PRÁTICA

SENSORES COLETAM DADOS AUTOMATICAMENTE

DADOS SÃO USADOS PARA ANÁLISE E DECISÃO

INTEGRAÇÃO DIRETA COM BIG DATA

TIPOS DE DADOS – CONCEITO

OS DADOS PODEM ASSUMIR DIFERENTES FORMATOS

ISSO IMPACTA DIRETAMENTE ARMAZENAMENTO E PROCESSAMENTO

TIPOS DE DADOS – CLASSIFICAÇÃO

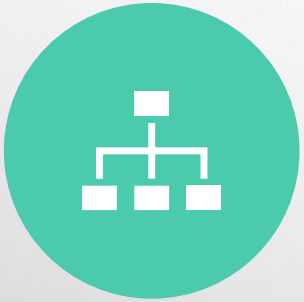

ESTRUTURADOS: TABELAS RELACIONAIS

SEMIESTRUTURADOS: JSON E XML

NÃO ESTRUTURADOS: IMAGENS, VÍDEOS, TEXTOS

PROCESSAMENTO DE DADOS – CONCEITO

DEFINE COMO OS DADOS SÃO TRATADOS AO LONGO DO TEMPO

PODE OCORRER EM LOTE OU EM TEMPO REAL

BATCH VS STREAMING

- Batch: processamento em blocos (dados históricos)
- Streaming: processamento contínuo em tempo real
- Streaming trabalha com múltiplas fontes

HADOOP – CONCEITO

FRAMEWORK PARA ARMAZENAMENTO E PROCESSAMENTO DISTRIBUÍDO

PROJETADO PARA GRANDES VOLUMES DE DADOS

HADOOP – COMPONENTES

HDFS: ARMAZENAMENTO DISTRIBUÍDO

YARN: GERENCIAMENTO DE RECURSOS

MAPREDUCE: PROCESSAMENTO DE DADOS

HDFS – CONCEITO

SISTEMA DE ARQUIVOS DISTRIBUÍDO

DIVIDE DADOS EM BLOCOS E DISTRIBUI EM VÁRIOS NÓS

HDFS – ESTRUTURA

NameNode: gerencia metadados

DataNode: armazena os blocos de dados

HDFS – TOLERÂNCIA A FALHAS

Dados são replicados em múltiplos nós

Garante disponibilidade mesmo com falhas

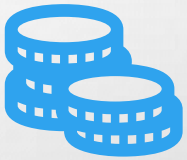

Baseado em hardware comum (commodity)

YARN – CONCEITO

Gerenciador de recursos do Hadoop

Responsável por distribuir e controlar tarefas

ARQUITETURAS DE DADOS – CONCEITO

Diferentes soluções atendem diferentes necessidades de dados

Escolha depende do tipo de análise e volume

DATA WAREHOUSE

Um repositório centralizado de dados estruturados, usados principalmente para análise e geração de relatórios.

Características:

Dados organizados em tabelas e colunas (bancos relacionais).	Ideal para BI (Business Intelligence).	Alta performance em consultas analíticas.

DATA MART

Um subconjunto de um Data Warehouse, focado em um departamento ou área específica (como vendas, marketing, etc).

Características:

Dados organizados em tabelas (bancos relacionais).	Facilita o acesso rápido e direto para equipes específicas.	Facilita o acesso rápido e direto para equipes específicas.

DATA LAKE

Um grande repositório que armazena dados em seu formato bruto, estruturados e não estruturados.

Características:

Pode conter arquivos CSV, imagens, vídeos, logs, etc.	Flexível e escalável, mas exige mais processamento para análise.	Armazenar dados de sensores IoT, cliques de usuários, áudios para análise posterior.

DATA LAKEHOUSE

Uma arquitetura que combina o melhor do Data Lake e do Data Warehouse.

Características:

Armazena dados brutos como o Data Lake.	Permite análises rápidas como um Data Warehouse.	Usa tecnologias que suportam dados estruturados e não estruturados.

RESUMO FINAL

- BIG DATA E 5 VS
- IOT E GERAÇÃO DE DADOS
- TIPOS DE DADOS
- PROCESSAMENTO (BATCH E STREAMING)
- HADOOP E SUAS FERRAMENTAS
- ARQUITETURAS DE DADOS
- DW – DM - DL